

Conclusions i Propostes de Futur

Classificador de Spam i Phishing

Valoració final del projecte i línies d'evolució per a futures versions.

1. Conclusions

Estructura de dades adequada

L'ús d'un ArbolBST per emmagatzemar les paraules sospeschoses permet inserció i cerca en $O(\log n)$ en cas mitjà, més eficient que una llista lineal $O(n)$. A més, el recompte de freqüència integrat al node evita recorreguts addicionals.

Detecció de typosquatting robusta

La distància de Levenshtein captura imitacions com 'santanderr.com' o 'g00gle.com' que escapen a les comparacions exactes. El lindar ≤ 2 equilibra sensibilitat i falsos positius.

Arquitectura extensible

El patró de disseny amb FiltroCorreo com a classe base permet afegir nous filtres sense modificar AnalizadorCorreo. El sistema és obert a l'extensió i tancat a la modificació (principi OCP).

Sistema de puntuació ponderat

Assignar pesos diferents a cada paraula (ex. 'cvv': 65 vs 'gratis': 25) permet graduar el risc. La classificació en tres nivells (SEGURO/SOSPECHOSO/PELIGROSO) ofereix flexibilitat d'acció.

Escaneig recursiu

La funció escanear_carpeta() gestiona correctament estructures de carpetes niuades, cosa habitual en clients de correu reals.

2. Limitacions actuals

BST no balancejat

L'arbre pot degenerar en llista si les paraules s'insereixen en ordre alfabètic. Això porta la cerca a $O(n)$. Una solució seria usar un AVL o un Red-Black Tree.

Diccionari estàtic

Les paraules spam i els dominis legítims estan hardcodejats. Qualsevol actualització requereix modificar el codi font.

Només analitza text pla

El filtre de paraules clau no processa HTML, imatges amb text (OCR) ni fitxers adjunts, vectors d'atac habituals en phishing modern.

Sense aprenentatge

El sistema no s'adapta a nous patrons d'atac. Un classificador basat en ML podria aprendre automàticament de nous exemples etiquetats.

Falsos positius possibles

Paraules com 'transferencia' o 'contraseña' poden aparèixer en correus legítims (p. ex. correus del banc autèntics).

3. Propostes de futur

1. Substituir BST per AVL o Red-Black Tree

Garantiria $O(\log n)$ en el pitjor cas per a totes les operacions, eliminant la degradació per ordre d'inserció.

2. Diccionari extern en JSON/BD

Carregar les paraules spam i els dominis des d'un fitxer de configuració o base de dades permetria actualitzacions sense recompilar.

3. Filtre HTML i adjunts

Afegir un FiltroPorHTML que parsegi el contingut HTML del correu (amb BeautifulSoup) i un FiltroPorAdjunts que comprovi extensions sospeschoses (.exe, .js, .vbs).

4. Integració amb ML

Entrenar un classificador Naive Bayes o SVM sobre un dataset etiquetats (ex. SpamAssassin Public Corpus) i integrar-lo com un nou FiltroCorreo, mantenint la compatibilitat amb l'arquitectura actual.

5. API REST

Exposar l'analitzador com a servei web (Flask/FastAPI) per integrar-lo amb clients de correu reals via plugins.

6. Interfície gràfica

Afegir una GUI senzilla (Tkinter o web) per visualitzar els resultats de manera més accessible per a usuaris no tècnics.

7. Tests automàtics

Implementar una suite de tests unitaris (pytest) per a cada filtre i tests d'integració amb correus .eml reals etiquetats.

4. Valoració final

El projecte assoleix l'objectiu principal: classificar correus .eml detectant spam i phishing mitjançant tècniques de cerca eficient (BST) i similitud de cadenes (Levenshtein).

L'arquitectura orientada a objectes amb herència i polimorfisme fa el sistema fàcilment extensible.

Les principals àrees de millora són la robustesa de l'arbre (balanç), la cobertura de vectors d'atac moderns (HTML, adjunts) i la incorporació d'aprenentatge automàtic per adaptar-se a noves amenaces sense intervenció manual.